

Discrete Curvature Graph Information Bottleneck

AAAI 25'

CHAE WON PARK

Network Science Lab
Dept. of Artificial Intelligence
The Catholic University of Korea

E-mail: codnjsld@catholic.ac.kr

Contents



- Introduction
 - Limitation of previous work
 - Contributions
- Background
 - Related Work
 - Variation Information Bottleneck
 - Discrete Graph Curvature
- Discrete curvature Graph Information Bottleneck
 - ConvGIB
 - Framework
 - Algorithm
 - Theoretical analyses
- Experiments
 - Node classification
 - Parameter sensity
 - Learned Graph curvature
 - Training stability

Limitation of Previous work

- 그래프의 속성은 전체 그래프 구조보다는 downstream task와 관련된 일부 핵심 구조에 의해 결정되는 경우가 많음.
- 기존의 2가지 주요 연구 방향
 - 정보 이론적 접근 : 핵심 subgraph 구조의 탐색 및 mining에 중점을 둠. (어떤 데이터를 보낼지에만 집중)
 - Messaging perspective : over-smoothing, over-squashing 과 같은 messaging 문제를 해결하기 위해 기하학적 지표를 활용



정보 이론 + 그래프 기하학적 관점으로

Task와 관련된 유효한 정보의

최적의 전달 방식을 학습할 수 있는

새로운 프레임워크를 개발할 수 있을까?

Related Work

- **Graph Structure Learning (GSL)**
 - 인접 행렬과 GNN 매개변수를 동시에 최적화하여 특정한 downstream task에 가장 적합한 그래프 구조를 학습함.
 - 시간 복잡도가 높고, 대규모 그래프에서 scalability가 제한됨.
- **Graph Curvature**
 - **Re-weighting approach**
 - 노드나 엣지의 가중치를 조정하여 정보 전파 경로에 영향을 미침.
 - BORF (paired nodes의 이웃을 재구성) : Ollivier-Ricci 곡률 사용 -> 노이즈가 있는 엣지의 영향을 증폭시킬 가능성
 - SDRF (이웃 재구성) : Forman 곡률 사용 -> 그래프 경계 영역의 노드를 처리하는 데에 약점. 계산량 ↑
 - **Re-wiring approach**
 - 그래프 구조를 직접적으로 변형하여 정보 전달을 최적화함.
 - 그래프 곡률 정보를 GNN에 통합하여 복잡한 구조를 가진 그래프의 성능을 크게 향상시킴.

Variational Information Bottleneck (VIB)

- **Information Bottleneck (IB)**

- Task-relevant information은 최대화하고, irrelevant information은 압축시킴.
- Input data X , label Y , IB principle aims to learn the minimal sufficient representation Z
- β (라그랑주 승수) : trading off sufficiency and minimality.

$$Z = \arg \min_Z - \underset{\uparrow}{I}(Z, Y) + \beta I(Z, X), \quad (1)$$

상호 정보의 양 측정

- **Variational Information Bottleneck (VIB)**

- 불규칙한 그래프 데이터에 대한 GIB (Graph Information Bottleneck)
- 원본 구조를 압축하고 노드가 이웃으로부터 오는 가장 효율적인 정보를 집계하도록 함.

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \int dZ p(Z|X_i) \log q(Y_i|Z) + \beta \mathcal{D}_{KL}(p(Z|X_i), r(Z)), \quad (2)$$

$\uparrow$
 두 확률분포 사이의 차이

Discrete Graph Curvature

- 질량 분포 (확률 분포)

- α : 노드 u 자신이 자신의 정보(질량)를 얼마나 보존하는지를 나타냄.

$$m_u^\alpha(v) = \begin{cases} \alpha, & v = u, \\ (1 - \alpha) \frac{1}{|N(u)|}, & v \in N(u), \\ 0, & \text{otherwise.} \end{cases} \quad (3)$$

- Olivier-Ricci 곡률 (K)

- Wasserstein 거리 : message passing 패턴을 정량화

$$Ric^\alpha(i, j) = 1 - \overset{\text{Eq3}}{\frac{W(m_i^\alpha, m_j^\alpha)}{d(i, j)}}, \quad (4)$$

노드 i, j 에서 확률 분포 간의
Wasserstein 거리

CurvGIB

- Ricci flow와 VIB를 기반으로 하는 그래프 구조 supervised 최적화 모델을 제안함. (CurvGIB)
- 중요한 정보를 전달하는 패턴 학습에 집중하며, 그래프 구조를 직접 재구성하거나 학습하는 것과는 다름.
 - IB 원리로 GNN 학습에서 중요한 정보 찾기 -> 최적의 전달 지표(IB-Curvature) 학습
- Olivier-Ricci 곡률 계산에 사용되는 질량 분포를 라플라시안 행렬 기반으로 재정의
- 기존 Wasserstein 거리 계산 복잡성, 미분 불가능성 해결
- **라플라시안 행렬**

$$L^{\alpha} = \alpha I + (1 - \alpha) D^{-1} A$$

- **라플라시안 기반 질량 분포**

$$[L^{\alpha}]_{ij} = \begin{cases} \alpha, & i = j \\ (1 - \alpha) \frac{1}{D_{ii}}, & [A]_{ij} = 1 \\ 0, & \text{Otherwise} \end{cases} \quad (5)$$

노드 i, j 사이에 엣지 존재

CurvGIB

- IB Curvature
 - $\mathbf{Z}$ 에 대해 미분 가능


$$\kappa_{\text{IB}}(i, j) = 1 - \frac{[L^\alpha(\mathbf{A})f(\mathbf{Z})]_i - [L^\alpha(\mathbf{A})f(\mathbf{Z})]_j}{d(\mathbf{z}_i, \mathbf{z}_j)}, l \quad (6)$$

Affine transform

- Curvature Graph Information Bottleneck

$$\begin{aligned} \mathbf{Z}_{\text{IB}}, \kappa_{\text{IB}} &= \arg \min_{\mathbf{Z}, \kappa} \text{CurvGIB}(\mathbf{X}, \mathbf{Y}, \mathbf{Z}, \kappa) \\ &\triangleq \arg \min_{\mathbf{Z}, \kappa} [-I(\mathbf{Z} \mid \kappa; \mathbf{Y}) + \beta I(\mathbf{Z} \mid \kappa; \mathbf{X})], \end{aligned} \quad (7)$$

κ 가 주어진 상태에서 상관관계



CurvGIB

- Eq7의 상호 정보는 복잡한 확률 분포를 포함하고 있어 실제 딥러닝 모델에서 계산하기 어려움.
- VIB 도입 : variational distribution을 사용하여 상호 정보의 하한/상한을 도출하여 최적화
- Z가 Y의 정보를 많이 담아야 함. 최대화

$$I(\mathbf{Z}|\kappa; \mathbf{Y}) \geq \int p((\mathbf{Z}, \mathbf{Y})|\kappa) \log q(\mathbf{Y} | (\kappa, \mathbf{Z})) d\mathbf{Y} d\kappa d\mathbf{Z}, \quad (8)$$

where q is the variational posterior distribution.

- Z가 X의 불필요한 정보를 압축해야 함. 최소화

$$I(\mathbf{Z}|\kappa; \mathbf{X}) \leq \int p(\mathbf{X}) p(\mathbf{Y} | (\mathbf{X}, \kappa)) \log \frac{p(\mathbf{Y} | (\mathbf{X}, \kappa))}{r(\mathbf{Z}|\kappa)} d\kappa d\mathbf{X} d\mathbf{Z}, \quad (9)$$

where r is the variational posterior distribution.

Framework




Figure 3: The proposed CurvGIB principle and its overall framework.

Framework

- Ricci flow + 곡률 인식 GNN 기반으로 한 bi-level optimization framework 제안
- **IB-Curvature and Representation Learning**

1. 재구성된 구조의 Ricci 곡률 업데이트

$$\kappa_{IB}(i, j) = 1 - \frac{[L^\alpha(A^*)f(\mathbf{Z})]_i - [L^\alpha(A^*)f(\mathbf{Z})]_j}{d(\mathbf{z}_i, \mathbf{z}_j)}. \quad (10)$$

2. Aggregate function (affine transform 사용)

$$\mathbf{Z}_\kappa = \text{CurvGNN}(\mathbf{X}, \mathbf{Y}, \kappa_{IB})$$

$$\text{AGG}(\mathbf{Z}^{(l)}, \kappa_{IB}) = \sigma \left(\underset{\substack{\text{Activate} \\ \text{function}}}{\mathbf{Z}^{(l)}} + \underset{\substack{\text{Self} \\ \text{loop}}}{f} \left(\underset{\substack{\text{Affine} \\ \text{transform}}}{\mathcal{K}^{(l)}(\kappa_{IB})} \cdot \underset{\substack{\text{엣지} \\ \text{가중치} \\ \text{matrix}}}{\mathbf{Z}_j^{(l)}} \right) \right), \quad (11)$$

노드
표현

Framework

- Ricci flow + 곡률 인식 GNN 기반으로 한 bi-level optimization framework 제안
- **IB-Curvature and Representation Learning**

3. 업데이트된 곡률 κ 를 사용하여 $\mathbf{Z}$ 전달 최적화

$$\begin{aligned}\mathbf{Z}_{\kappa} &= \arg \min_{\mathbf{Z}_{\kappa}} \text{CurvGIB}(\mathbf{X}, \mathbf{Y}, \mathbf{Z}, \kappa), \\ &= \arg \min_{\mathbf{Z}_{\kappa}} (-I(\mathbf{Z}_{\kappa}; Y) + \beta I(\mathbf{Z}_{\kappa}; \mathbf{X})),\end{aligned}\tag{12}$$

Framework

- Ricci flow + 곡률 인식 GNN 기반으로 한 bi-level optimization framework 제안
- **Structure Refinement with IB-Curvature**

4. Discrete Ricci flow 정의

- IB-Curvature에 대한 엣지 가중치 행렬 $\mathbf{K}$ 를 가진 엣지 가중치 그래프로 정의함

$$\mathcal{K}^{(l+1)} = \left(1 - \kappa_{\text{IB}}^{(l)}\right) d^{(l)}(\mathbf{Z}_{\kappa}, \mathbf{Z}_{\kappa}^T), \quad (13)$$

eq6

5. IB-curvature 가중치와 그래프 표현 학습을 통해 엣지 샘플링 확률을 최적화

$$[\mathbf{A}^*]_{ij} \sim \text{Ber}(\pi_{ij}) \begin{matrix} \text{확률의 범위 변환} \\ -\text{무한대} \sim +\text{무한대} \end{matrix} \quad \text{노이즈}$$

$$\approx \text{sigmoid} \left(\frac{1}{\tau} \left(\log \frac{\pi_{u,v}}{1 - \pi_{u,v}} + \log \frac{\epsilon}{1 - \epsilon} \right) \right), \quad (14)$$

where $\epsilon \sim \text{Uniform}(0, 1)$ and $\tau \in \mathbb{R}^+$ is the temperature.

작아질수록 이산적

Framework

- Ricci flow + 곡률 인식 GNN 기반으로 한 bi-level optimization framework 제안
- **Structure Refinement with IB-Curvature**

6. Likelihood를 최대화함으로써, A^* 를 최적화

$$A^* = \arg \min_{A^*} \left[- \sum_{i=1}^N \sum_{j=1}^N \log p([A]_{ij} = 1 \mid A^*) \right]. \quad (15)$$

A*가 주어졌을 때 원본 그래프에서 엣지가 존재할 확률

- **Bi-level Optimization**

$$\begin{aligned} & \min \text{CurvGIB}(\mathbf{X}, \mathbf{Y}, \mathbf{Z}_\kappa, \kappa_{\text{IB}}), \\ & \text{s.t. } \kappa_{\text{IB}} \in \arg \min_{\kappa_{\text{IB}}} \text{IBCurv}(\mathbf{Z}_\kappa). \end{aligned} \quad (16)$$

$$\text{IBCurv}(\mathbf{Z}_\kappa) = \sum_{ij} (1 - \kappa_{\text{IB}}(i, j)) d(\mathbf{z}_i, \mathbf{z}_j)$$

Algorithm

Algorithm 1: The overall process of CurvGIB

Input: Graph $G = (X, A)$ with label Y ; Number of training epochs $E, E1, E2$;

Output: weighted node representation Z , predicted label $\hat{Y}$

```

1 Parameter initialization;
2 Initialization  $\kappa$  with Eq.(10)
3 for  $i = 0, 1, 2, \dots, E$  do
    // IB-Curvature and
    // Representation Learning
4   for  $i = 0, 1, 2, \dots, E1$  do
5     Aggregate node information with Eq.(11)
6     Optimize the first phase with Eq.(12)
7   end
    // Structure Refinement with
    // IB-Curvature
8   for  $i = 0, 1, 2, \dots, E2$  do
9     Calculate edge weight matrix  $\mathcal{K}$  with Eq.(13)
10    Sample structures with Bernoulli
11    distribution by using  $\mathcal{K}$  as a probability
12    matrix with Eq.(14)
13    Optimize the second phase with Eq.(15)
14  end
15  Optimize the overall framework with Eq.(16)
16 end
    
```


Node classification

	Method	Cora		CiteSeer		PUBMED		CS		PHYSICS		AMAZON-C		AMAZON-P	
		ACC	Macro-F1	ACC	Macro-F1	ACC	Macro-F1	ACC	Macro-F1	ACC	Macro-F1	ACC	Macro-F1	ACC	Macro-F1
GNN	GCN	81.5±0.5	81.9±1.0	70.9±0.5	<u>82.4±0.9</u>	79.0±0.3	<u>81.8±0.5</u>	91.1±0.5	82.5±0.6	92.8±1.0	81.8±0.5	82.6±2.4	82.4±0.6	91.2±1.2	81.4±0.4
	GAT	83.0±0.7	76.8±17.8	72.5±0.7	77.4±17.9	79.0±0.3	72.6±23.4	90.5±0.6	75.8±18.9	92.5±0.9	74.5±21.1	78.0±19.0	75.9±21.4	85.1±20.3	76.1±19.7
	GIN	86.6±0.4	77.6±8.9	63.4±0.6	77.9±8.5	86.6±0.1	76.8±7.7	53.3±0.4	78.5±8.2	86.6±0.1	75.7±7.7	54.3±19.0	77.7±8.9	51.4±17.0	77.3±7.8
	GraphSAGE	83.4±3.2	<u>82.2±8.1</u>	73.4±4.9	84.7±8.5	<u>86.9±4.7</u>	86.1±5.5	92.4±5.7	84.0±8.2	<u>95.0±4.8</u>	83.7±7.0	80.4±13.7	84.2±7.3	89.7±7.7	<u>85.1±6.4</u>
IB	SDRF	86.3±0.3	58.8±29.6	72.6±0.3	59.5±13.7	85.2±0.1	66.4±23.1	92.2±0.1	65.4±25.5	OOM	OOM	<u>86.6±0.2</u>	60.0±24.9	91.6±0.3	63.9±25.6
	BORF	<u>87.5±0.2</u>	62.7±26.7	<u>73.8±0.2</u>	58.7±14.3	86.1±0.4	68.0±21.5	<u>93.1±0.1</u>	71.8±21.9	OOM	OOM	OOM	OOM	<u>93.6±0.2</u>	66.6±24.6
	CurvGN-n	82.7±0.7	78.3±0.5	72.1±0.6	65.4±0.4	79.2±0.5	75.4±0.8	92.9±0.3	86.4±0.8	94.3±0.2	85.2±0.6	86.5±0.7	69.1±2.2	92.5±0.5	80.6±1.7
GSL	SUBLIME	84.2±0.5	71.7±0.5	73.5±0.6	66.4±1.4	81.0±0.6	73.7±1.6	92.3±0.7	<u>87.4±1.7</u>	94.2±0.3	91.9±0.5	72.3±0.5	42.0±4.0	81.3±0.3	66.6±2.2
	MVPOOL-SL	83.6±0.4	78.1±7.6	72.6±0.5	61.1±3.2	80.0±0.4	60.1±11.2	92.0±0.5	84.9±6.2	94.0±0.6	<u>90.0±1.1</u>	79.5±1.5	68.5±16.9	88.5±1.2	79.0±16.3
	CurvGIB	89.0±0.9	84.3±0.9	75.5±0.1	73.5±1.4	88.0±0.1	78.9±0.9	94.2±0.5	91.2±0.5	96.5±0.3	87.7±0.5	91.9±1.4	<u>83.9±1.7</u>	93.7±1.4	94.8±4.1


Table 2: Summary of node classification results: “average accuracy ± standard deviation”. Underlined: best performance of specific backbones, **bold**: best results of each dataset.

Parameter Sensity

- B 높을수록 정보를 많이 압축함, subgraph에서 정보를 충분히 학습하지 않음
- 모델 성능이 높은 적절한 값이 존재



(a) Parameter Sensitivity Analysis



(b) Performance with Different Ratio

Figure 4: Parameter sensity and robustness analysis on Cora and Citeseer.

Learned Graph Curvature

- BORF : 음수 곡률을 가진 엣지를 제거하는 경향
- VIB-GSL : 원래 그래프를 fully-connected graph로 처리하는 경향
- CurvGIB : 특별한 경향을 가지지 않고, 특정 데이터셋을 기반으로 메시지 전달에 가장 적합한 구조로 조정






Figure 6: Distributions of Ricci curvature and visualizations of sampling sub-structures after learning on Cora.

Training stability


- GCN을 제외한 나머지 모델들은 안정적으로 수렴
- CurvGIB는 GAT보다 2.5배 빠르게, BORF 모델보다 2배 빠르게 수렴
 - 중요한 정보 전달을 위해 그 구조를 유지하도록 모델을 개선하는 원리



(a) Cora



(b) CiteSeer



(c) Pubmed

Figure 5: Learning Stability Analysis on Different Datasets

Contributions

- **CurvGIB framework**
 - Ricci 곡률을 결합해서, 복잡한 그래프 구조에서도 정보 전달의 효율을 기하학적 관점에서 향상시킴
 - 직접적인 그래프 구조 변형이나 그래프 구조 학습에 비해 정확하고 효과적인 접근 방식
- **Discrete Curvature 최적화**
 - 특정 downstream task에 대한 최적 정보 전달 패턴 학습을 위해 IB 원리 확대
 - 계산 복잡성을 낮추기 위한 곡률 최적화 근사
 - 실험적 검증으로 우수한 성능 입증

Future Work

- 현재 연구는 주로 node-level에서 이루어지고, graph-level로 확장되지 않음
- 향후 연구에서 CurvGIB가 그래프 수준의 task에서 어떻게 적용될 수 있는지에 대한 방안을 모색해야 함.

