

E(n) Equivariant Graph Neural Network

CHAE WON PARK

Network Science Lab
Dept. of Artificial Intelligence
The Catholic University of Korea

E-mail: codnjsld@catholic.ac.kr

Contents



- Introduction
 - Background
 - Equivariance
- Method
 - Equivariance Graph Neural Network
 - Equivariant Graph Convolutional Layer
 - Equivariance Proof
 - Extending EGNNs for vector type representations
 - Equivariance Proof
- Experiments
 - N-body system
 - Graph Autoencoder
 - Molecular data – QM9
- Conclusion
 - Contribution
 - Limitation

Background

- 딥러닝이 수작업으로 만든 많은 특징들을 대체하고 있지만, 여전히 모델이 데이터의 규칙을 더 잘 학습하게 하기 위해 귀납적 편향이 필수적임
- **귀납적 편향(inductive bias)** : 머신러닝 모델이 학습 데이터 외의 새로운 입력값에 대한 결과를 예측하기 위해 사용하는, 사전에 정의된 가정이나 제한 조건
- 현실 세계의 문제(분자 구조, 물리 시스템 등)는 3D 공간에서의 회전, 평행이동, 반사에 대해 대칭성을 가짐(symmetry)
- 이 대칭성을 모델 구조에 직접 반영하는 방법이 등변성(Equivariance)을 강제하는 것이다.
-> 이를 통해 모델이 모든 방향의 데이터를 따로 학습할 필요 없이, 보다 효율적으로 일반화할 수 있음

Equivariance

- 등변성 : 입력에 특정 변환이 가해졌을 때, 출력도 동일한 변환을 따르는 성질
- 이 식이 항상 만족하면 함수는 변환 G 에 대해 등변성을 가짐

$$\phi(T_g(\mathbf{x})) = S_g(\phi(\mathbf{x}))$$

The diagram illustrates the components of the equivariance equation $\phi(T_g(\mathbf{x})) = S_g(\phi(\mathbf{x}))$. Three arrows point from descriptive text boxes to terms in the equation:

- An arrow points from the box "입력을 받아 출력을 생성하는 함수" (Function that takes input and generates output) to the symbol ϕ .
- An arrow points from the box "입력 공간 x 에 작용하는 변환" (Transformation acting on input space x) to the term $T_g(\mathbf{x})$.
- An arrow points from the box "출력 공간 y 에 작용하는 변환" (Transformation acting on output space y) to the symbol S_g .

입력 데이터 변환 후 그 변환된 입력으로 함수 실행 = 입력 데이터에 함수 실행 후 그 결과에 해당하는 변환 적용

Equivariance

- 등변성 : 입력에 특정 변환이 가해졌을 때, 출력도 동일한 변환을 따르는 성질

- **Translation(평행이동) equivariance**

: 위치 변화에 따라 결과도 동일하게 변화

$$\mathbf{y} + \mathbf{g} = \phi(\mathbf{x} + \mathbf{g})$$

- **Rotation(회전) and Reflection(반사) equivariance**

: 방향 변화에 따라 결과도 동일하게 변화

$$Q\mathbf{y} = \phi(Q\mathbf{x})$$

- **Permutation(순열) equivariance**

: 입력 데이터의 순서 변화에 따라 결과도 동일하게 변화

$$P(\mathbf{y}) = \phi(P(\mathbf{x}))$$




Figure 1. Example of rotation equivariance on a graph with a graph neural network ϕ

Equivariant Graph Neural Network

- 기존 모델의 한계
 - 높은 계산 복잡도 : 중간 레이어에서 구면 조화 함수 같은 고차원 표현을 사용하여 계산량이 많고 표현이 복잡함
 - **고차원 표현(higher-order representation)** : 복잡한 형태의 표현(대칭성 등)을 처리하고 다양한 종류의 데이터 간의 변환을 효과적으로 모델링하는데 사용됨. 계산 비용↑, 차원 확장 제한(3차원 특화)
- **E(n) 대칭성** : Euclidean group의 약자, n차원 유클리드 공간에서의 대칭성
 - 평행이동, 회전, 반사를 모두 포함하는 집합
 - 기존 연구에서는 주로 E(3) or SE(3)에만 집중 (3차원)
 - 숫자 대신 임의의 차원을 뜻하는 n을 씀 (임의의 차원으로 확장)
- 표현력의 이점
 - E(n) 등변성을 보장함으로써 데이터의 본질적인 속성에 집중할 수 있음
 - E(n) 변환된 데이터 샘플들을 별도로 구분하여 학습할 필요가 없음 -> 데이터 양↓, 비용 ↓

Equivariant Graph Convolution Layer

- 구면 조화 함수 같은 복잡한 고차 표현 대신, 상대적 거리를 이용한 간단한 수식으로 구성
- 4단계 업데이트 수식

① Edge Update (엣지 메시지 생성)

$$\mathbf{m}_{ij} = \phi_e \left(\mathbf{h}_i^l, \mathbf{h}_j^l, \|\mathbf{x}_i^l - \mathbf{x}_j^l\|^2, a_{ij} \right)$$

- 엣지 메시지가 두 노드의 feature, 두 노드 간의 상대적 위치, 엣지 속성에 의해 결정됨
- 기존 GNN이 노드 임베딩과 엣지 속성만을 고려하는 것과 달리, 노드의 위치 좌표를 입력으로 써서 엣지 연산이 입력 위치 좌표의 E(n) 대칭성에 대해 등변성을 유지할 수 있게 됨

② Coordinate Update (노드 좌표 업데이트)

$$\mathbf{x}_i^{l+1} = \mathbf{x}_i^l + C \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{ij})$$

- 현재 위치에서 상대적 위치 차이를 이용해 위치를 옮김 (방향 벡터)
- 반경 방향으로만 입력을 이동시켜서 E(n) 등변성을 만족시킴

Equivariant Graph Convolution Layer

- 구면 조화 함수 같은 복잡한 고차 표현 대신, 상대적 거리를 이용한 간단한 수식으로 구성
- 4단계 업데이트 수식

③ Aggregate (메시지 취합)

$$\mathbf{m}_i = \sum_{j \neq i} \mathbf{m}_{ij}$$

- GNN과 동일한 집계 방법 (하나로 합침)
- 노드 i 에 대한 최종 메시지는 자기 자신을 제외한 나머지 노드 j 들로부터 오는 모든 메시지의 집합

④ Node Update (노드 특징 업데이트)

$$\mathbf{h}_i^{l+1} = \phi_h(\mathbf{h}_i^l, \mathbf{m}_i)$$

- 다음 레이어에서 노드 특징이 현재 레이어의 노드 특징과 이웃 노드들로부터 받은 정보를 바탕으로 업데이트됨

Equivariant Graph Convolution Layer - Equivariance Proof

- EGNN이 입력 좌표 x 에 대해 $E(n)$ 대칭성을 보존하는지 증명하기 위함

$$Q\mathbf{x}^{l+1} + g, \mathbf{h}^{l+1} = \text{EGCL}(Q\mathbf{x}^l + g, \mathbf{h}^l)$$


- 증명 과정 :

- ① 특징 $\mathbf{h}_0$ 이 x 에 대한 $E(n)$ 변환에 불변이라고 가정 (x 의 절대적 위치/방향에 대한 정보를 $\mathbf{h}_0$ 에 담지 않음)
- ② 엣지 임베딩 (m_{ij})도 $E(n)$ 변환에 대해 불변함 (특징 $\mathbf{h}_i, \mathbf{h}_j$ 와 입력 좌표 간의 제곱 거리 $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ 사용)

$$\|\mathbf{x}_i^l + g - [\mathbf{x}_j^l + g]\|^2 = \|\mathbf{x}_i^l - \mathbf{x}_j^l\|^2 \quad \& \quad \|Q\mathbf{x}_i^l - Q\mathbf{x}_j^l\|^2 = (\mathbf{x}_i^l - \mathbf{x}_j^l)^\top Q^\top Q (\mathbf{x}_i^l - \mathbf{x}_j^l) = (\mathbf{x}_i^l - \mathbf{x}_j^l)^\top \mathbf{I} (\mathbf{x}_i^l - \mathbf{x}_j^l) = \|\mathbf{x}_i^l - \mathbf{x}_j^l\|^2$$

평행 이동에 대해 불변

회전, 반사에 대해 불변



$$\mathbf{m}_{i,j} = \phi_e \left(\mathbf{h}_i^l, \mathbf{h}_j^l, \|Q\mathbf{x}_i^l + g - [Q\mathbf{x}_j^l + g]\|^2, a_{ij} \right) = \phi_e \left(\mathbf{h}_i^l, \mathbf{h}_j^l, \|\mathbf{x}_i^l - \mathbf{x}_j^l\|^2, a_{ij} \right)$$

$x \rightarrow Qx + g$ 에 대해 불변

Equivariant Graph Convolution Layer - Equivariance Proof


- EGNN이 입력 좌표 x 에 대해 $E(n)$ 대칭성을 보존하는지 증명하기 위함

$$Q\mathbf{x}^{l+1} + g, \mathbf{h}^{l+1} = \text{EGCL}(Q\mathbf{x}^l + g, \mathbf{h}^l)$$

- 증명 과정 :

- ③ 좌표 업데이트도 $E(n)$ 변환에 대해 불변함

$$\begin{aligned}
 Q\mathbf{x}_i^l + g + C \sum_{j \neq i} (Q\mathbf{x}_i^l + g - Q\mathbf{x}_j^l - g) \phi_x(\mathbf{m}_{i,j}) &= Q\mathbf{x}_i^l + g + QC \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{i,j}) \\
 x \rightarrow Qx + g \text{에 대해 불변} &= Q \left(\mathbf{x}_i^l + C \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{i,j}) \right) + g \\
 &= Q\mathbf{x}_i^{l+1} + g \quad \uparrow \text{좌표 업데이트 공식}
 \end{aligned}$$



$$Q\mathbf{x}_i^{l+1} + g = Q\mathbf{x}_i^l + g + C \sum_{j \neq i} (Q\mathbf{x}_i^l + g - [Q\mathbf{x}_j^l + g]) \phi_x(\mathbf{m}_{i,j})$$

- ④ 노드 업데이트도 $E(n)$ 변환에 대해 불변함 (불변하다고 증명한 h 과 m_{ij} 를 사용)

Equivariant Graph Convolution Layer - Equivariance Proof

- EGNN이 입력 좌표 x 에 대해 $E(n)$ 대칭성을 보존하는지 증명하기 위함

$$Q\mathbf{x}^{l+1} + g, \mathbf{h}^{l+1} = \text{EGCL}(Q\mathbf{x}^l + g, \mathbf{h}^l)$$

- EGNN 모델이 입력 좌표에 대한 $E(n)$ 변환을 출력 좌표에 동일하게 적용하고, 출력 특징은 변환에 불변함(영향을 받지 않음)을 보여 모델이 $E(n)$ 등변성을 만족함을 증명했다.
- h (특징), m (엣지 임베딩) : 불변
- x (좌표) : 등변

Extending EGNNs for vector type representations

- EGNN에 운동량을 포함시킴
- 입자의 속도를 각 레이어에서 추정하거나, 초기 속도 값이 0이 아닌 경우에 초기 속도 값으로 활용하는 데 유용

$$\mathbf{v}_i^{l+1} = \phi_v(\mathbf{h}_i^l) \mathbf{v}_i^{\text{init}} + C \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{ij})$$

- EGCL을 확장하여 노드 특징, 좌표뿐만 아니라 속도 정보도 함께 다룸
- 노드 특징을 입력받아 초기 속도를 결정하고, 위치 벡터 차이와 메시지 기반 가중치 곱을 합산하여 속도 변화를 계산함

$$\mathbf{x}_i^{l+1} = \mathbf{x}_i^l + \mathbf{v}_i^{l+1}$$

- 업데이트 된 속도 벡터가 현재 위치에 더해져 다음 레이어의 위치가 결정됨

$$\mathbf{h}^{l+1}, \mathbf{x}^{l+1}, \mathbf{v}^{l+1} = \text{EGCL}[\mathbf{h}^l, \mathbf{x}^l, \mathbf{v}^{\text{init}}, \mathcal{E}]$$

- EGCL이 노드 특징, 좌표, 초기 속도, 엣지 정보를 입력으로 받아 다음 레이어의 노드 특징, 좌표, 속도를 출력함 (초기 속도가 0이면 기존 EGNN과 동일)

Extending EGNNs for vector type representations – Equivariance Proof


- 기존 EGNN의 좌표 업데이트 부분을 속도를 포함하는 두 단계로 나눈 변형에 대한 증명
- 이전에 증명한 h 와 m 은 $E(n)$ 변환에 대해 불변하다는 것을 활용함

$$\mathbf{h}^{l+1}, Q\mathbf{x}^{l+1} + g, Q\mathbf{v}^{l+1} = \text{EGCL}[\mathbf{h}^l, Q\mathbf{x}^l + g, Q\mathbf{v}^{\text{init}}, \mathcal{E}]$$

- 증명 과정
 - 속도 업데이트의 등변성

$$\begin{aligned} \phi_v(\mathbf{h}_i^l) Q\mathbf{v}_i^{\text{init}} + C \sum_{j \neq i} (Q\mathbf{x}_i^l + g - [Q\mathbf{x}_j^l + g]) \phi_x(\mathbf{m}_{ij}) &= Q\phi_v(\mathbf{h}_i^l) \mathbf{v}_i^{\text{init}} + QC \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{ij}) \\ &= Q \left(\phi_v(\mathbf{h}_i^l) \mathbf{v}_i^{\text{init}} + C \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{ij}) \right) \\ &= Q\mathbf{v}_i^{l+1} \end{aligned}$$

↑ 좌표 업데이트 공식



$$Q\mathbf{v}_i^{l+1} = \phi_v(\mathbf{h}_i^l) Q\mathbf{v}_i^{\text{init}} + C \sum_{j \neq i} (Q\mathbf{x}_i^l + g - [Q\mathbf{x}_j^l + g]) \phi_x(\mathbf{m}_{ij})$$

Extending EGNNs for vector type representations – Equivariance Proof

- 기존 EGNN의 좌표 업데이트 부분을 속도를 포함하는 두 단계로 나눈 변형에 대한 증명
- 이전에 증명한 h 와 m 은 $E(n)$ 변환에 대해 불변하다는 것을 활용함

$$\mathbf{h}^{l+1}, Q\mathbf{x}^{l+1} + g, Q\mathbf{v}^{l+1} = \text{EGCL}[\mathbf{h}^l, Q\mathbf{x}^l + g, Q\mathbf{v}^{\text{init}}, \mathcal{E}]$$

- 증명 과정
 - 좌표 업데이트의 등변성

$$\begin{aligned} Q\mathbf{x}_i^l + g + Q\mathbf{v}_i^{l+1} &= Q(\mathbf{x}_i^l + \mathbf{v}_i^{l+1}) + g \\ &= Q\mathbf{x}_i^{l+1} + g \end{aligned} \quad \uparrow \text{좌표 업데이트 공식}$$

$$\Rightarrow Q\mathbf{x}_i^{l+1} + g = Q\mathbf{x}_i^l + g + Q\mathbf{v}_i^{l+1}$$


- EGNN 모델이 평행이동, 회전, 반사뿐만 아니라 속도 정보까지도 일관성 있게 처리할 수 있음을 보여줌

N-body system

- 동적 시스템, 특히 N-body 시스템을 모델링하는 데 EGNN 적용
- **동적 시스템** : 시간의 흐름에 따라 점 또는 점들의 집합이 기하학적 공간에서 어떻게 변화하는지를 정의하는 함수
- EGNN의 속도 추가 버전 사용

Method	MSE	Forward time (s)
Linear	0.0819	.0001
SE(3) Transformer	0.0244	.1346
Tensor Field Network	0.0155	.0343
Graph Neural Network	0.0107	.0032
Radial Field	0.0104	.0039
EGNN	0.0071	.0062

Table 2. Mean Squared Error for the future position estimation in the N-body system experiment, and forward time in seconds for a batch size of 100 samples running in a GTX 1080Ti GPU.



Graph Autoencoder

- Noise-GNN : 입력에 노이즈를 추가한 GNN
- EGNN이 우수한 성능을 가지고, 그래프 희소성(낮은 p_e 값)에 덜 민감하고 높은 성능을 유지함

Encoder	Community Small			Erdos&Renyi		
	BCE	% Error	F1	BCE	% Error	F1
Baseline	-	31.79	.0000	-	25.13	0.000
GNN	6.75	1.29	0.980	14.15	4.62	0.907
Noise-GNN	3.32	0.44	0.993	4.56	1.25	0.975
Radial Field	9.22	1.19	0.981	6.78	1.63	0.968
EGNN	2.14	0.06	0.999	1.65	0.11	0.998




Figure 5. In the Table at the left we report the Binary Cross Entropy, % Error and F1 scores for the test partition on the Graph Autoencoding experiment in the Community Small and Erdos&Renyi datasets. In the Figure at the right, we report the F1 score when overfitting a training partition of 100 samples in the Erdos&Renyi dataset for different values of sparsity p_e . The GNN is not able to successfully auto-encode sparse graphs (small p_e values) for the Erdos&Renyi dataset even when training and testing on the same small subset.

Molecular data – QM9

- QM9 데이터셋을 사용하여 여러 그래프 신경망 모델의 분자 특성 예측 성능을 비교한 결과

E(n) Equivariant Graph Neural Networks												
Task Units	α bohr ³	$\Delta\epsilon$ meV	ϵ_{HOMO} meV	ϵ_{LUMO} meV	μ D	C_ν cal/mol K	G meV	H meV	R^2 bohr ³	U meV	U_0 meV	ZPVE meV
NMP	.092	69	43	38	.030	.040	19	17	.180	20	20	1.50
Schnet	.235	63	41	34	.033	.033	14	14	.073	19	14	1.70
Cormorant	.085	61	34	38	.038	.026	20	21	.961	21	22	2.03
L1Net	.088	68	46	35	.043	.031	14	14	.354	14	13	1.56
LieConv	.084	49	30	25	.032	.038	22	24	.800	19	19	2.28
DimeNet++*	.044	33	25	20	.030	.023	8	7	.331	6	6	1.21
TFN	.223	58	40	38	.064	.101	-	-	-	-	-	-
SE(3)-Tr.	.142	53	35	33	.051	.054	-	-	-	-	-	-
EGNN	.071	48	29	25	.029	.031	12	12	.106	12	11	1.55

Table 3. Mean Absolute Error for the molecular property prediction benchmark in QM9 dataset. *DimeNet++ uses slightly different train/val/test partitions than the other papers listed here.

Contribution

- $E(n)$ 등변성을 만족하는 새로운 그래프 신경망 구조인 EGNN 제안 (임의의 n 차원으로 확장 가능)
- 기존의 고차 표현 대신 단순한 메시지 전달 메커니즘과 노드 좌표의 직접적인 업데이트 이용
- EGCL을 통해 노드 특징 임베딩과 노드 좌표를 함께 고려하고 업데이트함

Limitation

- 모든 $E(n)$ 등변성을 다루는 것은 아님

