

Strategies for pre-training Graph Neural Network

CHAE WON PARK

Network Science Lab
Dept. of Artificial Intelligence
The Catholic University of Korea

E-mail: codnjsld@catholic.ac.kr

Contents



- Introduction
 - Preliminaries of GNN
 - Naïve pre-training
 - Self-supervised methods for pre-training GNN
- Strategies
 - Node-level pre-training
 - Graph-level pre-training
- Experiment
 - ROC-AUC on Molecular (using GIN)
 - GNN Architectures with and Without Pre-training
- Conclusion
 - Conclusion
 - Contribution
 - Limitation

Preliminaries of GNN

- Supervised learning of graphs : 그래프를 입력으로 받아 최종 레이블 예측
- K-th layer : 이웃 노드와 엣지 정보를 aggregate하고 기존 정보와 combine해서 업데이트 함
pre-training으로 이때 사용하는 가중치(파라미터) 미리 세팅


$$h_v^{(k)} = \text{COMBINE}^{(k)} \left(h_v^{(k-1)}, \text{AGGREGATE}^{(k)} \left(\left\{ \left(h_v^{(k-1)}, h_u^{(k-1)}, e_{uv} \right) : u \in \mathcal{N}(v) \right\} \right) \right)$$

- READOUT : 그래프 전체의 representation을 얻기 위해 마지막 iteration K 에서 노드 feature을 풀링함

$$h_G = \text{READOUT}(\{h_v^{(K)} \mid v \in G\})$$


Naïve pre-training

- 기존의 사전 학습 방법은 local/global 둘 중 하나의 방식으로만 함
- 성능 향상이 미미하거나, negative transfer 가능성이 있다는 한계




Self-supervised methods for pre-training GNN

- 기존 연구의 한계를 극복하기 위해서 local, global level을 모두 학습할 수 있어야 한다.
- 직관적이지만 제한적인 사전학습 전략과 대조적




Node-level pre-training

- GNN이 그래프 내의 개별 노드들이 가진 의미론적, 구조적 정보를 잘 파악하도록 함
- Node embedding은 이후 Global level representation 만드는 데 중요한 기반이 됨
- 2개의 self-supervised 방법 제시



Node-level pre-training [Context Prediction]

- 그래프의 구조적 유사성을 기반으로 노드 임베딩을 학습
- 유사한 structural context에 위치한 노드들은 서로 유사한 임베딩을 가져야 함
- 노드 주변의 부분 그래프를 보고 해당 노드 예측



- K-hop neighborhood : 중심 노드로부터 최대 K-hop 떨어진 모든 노드와 엣지로 구성된 부분 그래프
- Context graph : r_1 과 r_2 사이에 있는 노드와 엣지로 구성된 부분 그래프
- Context Anchor Nodes : 두 계산에 모두 참여하는 교집합 (그래프 안에서 노드 위치 더 정확히 추론)

Node-level pre-training [Context Prediction]

K-hop neighborhood

- GNN이 실제로 연산을 수행하는 범위
- 중심 노드의 최종 임베딩을 결정하는 입력 데이터

Context graph


- 해당 노드가 그래프 전체에서 어떤 위치/역할을 하는지 결정
- Self-supervised Learning – 주변 맥락을 통해 성질을 추론하게 만듦

$$\sigma \left(h_v^{(K)\top} c_{v'}^{G'} \right) \approx \mathbf{1} \{v \text{ and } v' \text{ are the same nodes}\}$$

1. K-hop neighborhood graph를 GNN에 넣어서 노드 임베딩을 만든다.
2. Context Graph를 별도의 GNN에 넣어서 맥락 임베딩을 만든다.
3. 노드와 맥락 임베딩이 positive pair인지 negative pair인지 구분하도록 학습시킨다.
4. 유사도를 측정한다. (주변 맥락만 보고도 해당 노드를 추론할 수 있는 강력한 임베딩 능력)

Node-level pre-training [Attribute Masking]

- GNN이 Masked된 노드와 엣지를 이웃 구조에 기반해 예측하게 함
- 속성값 자체의 중요성 뿐만 아니라 속성이 그래프 내에서 어떻게 나타내는지에 대한 규칙성 학습
- 특정 도메인에 대한 domain knowledge를 학습



1. Masking : 노드/엣지 속성 중 일부(15%)를 random하게 선택하여 [mask] 토큰으로 대체
2. Prediction : GNN이 입력된 그래프 구조와 마스킹되지 않은 속성 정보를 기반으로 임베딩 계산
선형 모델이 masking attribute를 예측
3. Optimization : 예측값 사이의 Cross Entropy Loss 최소화하도록 학습 (도메인 특화 지식 내면화)

Node-level pre-training

Context Prediction

- 노드 자체의 속성이 부족한 그래프에서도 구조 정보만으로 강력한 학습 가능
- 구조적으로 유사한 패턴을 가진 노드들을 잘 학습함
- 너무 넓은 context를 사용하면 노이즈가 많아지거나 K-hop 과의 관계가 희석될 수 있음
- Negative Sampling 방법에 따라 학습 품질이 크게 바뀜
- Global structure

Attribute Masking

- 도메인 특화 지식을 학습하기에 적합
- 구조를 파악하는 능력은 상대적으로 약함
- Local Attribute

Graph-level pre-training

- GNN이 개별 노드 임베딩을 통합하여 전체 그래프를 대표하는 그래프 임베딩 생성하게 함
- 그래프 분류 같이 그래프 전체의 특성을 예측하는 downstream task에서 중요함


Supervised Graph-level Property Prediction

- 대규모의 라벨링된 그래프로 GNN 모델이 전체 그래프의 특정 도메인별 속성을 직접 예측하게 함
- Multi-task 학습 : 최대한 많이 동시에 예측함
- READOUT : 그래프 임베딩을 얻기 위해 GNN의 모든 노드 임베딩을 하나로 집계
- Prediction : 집계된 임베딩에 선형 분류기를 추가하여 각 속성에 대한 예측 수행
- 관련 없거나 상충되는 속성을 학습하면 성능 저하를 유발할 수도 있음

Graph-level pre-training

Structural Similarity Prediction

- 두 그래프 간의 구조적 유사성 예측 (그래프 편집 거리, 구조적 유사성 값)
- 데이터셋 크기가 커질수록 계산량이 매우 많아짐
- 그래프 간 ground truth(실제 유사도) 값 획득이 힘들



Graph-level pre-training

(b) Categorization of our pre-training methods

	Node-level	Graph-level
Attribute prediction	Attribute Masking	Supervised Attribute Prediction
Structure prediction	Context Prediction	Structural Similarity Prediction

ROC-AUC on Molecular (using GIN)

- Model: GIN, Split : scaffold split, Metric : ROE-AUC

Dataset		BBBP	Tox21	ToxCast	SIDER	ClinTox	MUV	HIV	BACE	Average
# Molecules		2039	7831	8575	1427	1478	93087	41127	1513	/
# Binary prediction tasks		1	12	617	27	2	17	1	1	/
Pre-training strategy		Out-of-distribution prediction (scaffold split)								
Graph-level	Node-level									
–	–	65.8 ±4.5	74.0 ±0.8	63.4 ±0.6	57.3 ±1.6	58.0 ±4.4	71.8 ±2.5	75.3 ±1.9	70.1 ±5.4	67.0
–	Infomax	68.8 ±0.8	75.3 ±0.5	62.7 ±0.4	58.4 ±0.8	69.9 ±3.0	75.3 ±2.5	76.0 ±0.7	75.9 ±1.6	70.3
–	EdgePred	67.3 ±2.4	76.0 ±0.6	64.1 ±0.6	60.4 ±0.7	64.1 ±3.7	74.1 ±2.1	76.3 ±1.0	79.9 ±0.9	70.3
–	AttrMasking	64.3 ±2.8	76.7 ±0.4	64.2 ±0.5	61.0 ±0.7	71.8 ±4.1	74.7 ±1.4	77.2 ±1.1	79.3 ±1.6	71.1
–	ContextPred	68.0 ±2.0	75.7 ±0.7	63.9 ±0.6	60.9 ±0.6	65.9 ±3.8	75.8 ±1.7	77.3 ±1.0	79.6 ±1.2	70.9
Supervised	–	68.3 ±0.7	77.0 ±0.3	64.4 ±0.4	62.1 ±0.5	57.2 ±2.5	79.4 ±1.3	74.4 ±1.2	76.9 ±1.0	70.0
Supervised	Infomax	68.0 ±1.8	77.8 ±0.3	64.9 ±0.7	60.9 ±0.6	71.2 ±2.8	81.3 ±1.4	77.8 ±0.9	80.1 ±0.9	72.8
Supervised	EdgePred	66.6 ±2.2	78.3 ±0.3	66.5 ±0.3	63.3 ±0.9	70.9 ±4.6	78.5 ±2.4	77.5 ±0.8	79.1 ±3.7	72.6
Supervised	AttrMasking	66.5 ±2.5	77.9 ±0.4	65.1 ±0.3	63.9 ±0.9	73.7 ±2.8	81.2 ±1.9	77.1 ±1.2	80.3 ±0.9	73.2
Supervised	ContextPred	68.7 ±1.3	78.1 ±0.6	65.7 ±0.6	62.7 ±0.8	72.6 ±1.5	81.3 ±2.1	79.9 ±0.7	84.5 ±0.7	74.2

Table 1: **Test ROC-AUC (%) performance on molecular prediction benchmarks using different pre-training strategies with GIN.** The rightmost column averages the mean of test performance across the 8 datasets. The best result for each dataset and comparable results (*i.e.*, results within one standard deviation from the best result) are bolded. The shaded cells indicate negative transfer, *i.e.*, ROC-AUC of a pre-trained model is worse than that of a non-pre-trained model. Notice that node- as well as graph-level pretraining are essential for good performance.

GNN Architectures with and Without Pre-training

- 특정 모델(GIN) 뿐만 아니라 다양한 GNN 모델에서의 성능 변화 비교

	Chemistry			Biology		
	Non-pre-trained	Pre-trained	Gain	Non-pre-trained	Pre-trained	Gain
GIN	67.0	74.2	+7.2	64.8 ± 1.0	74.2 ± 1.5	+9.4
GCN	68.9	72.2	+3.4	63.2 ± 1.0	70.9 ± 1.7	+7.7
GraphSAGE	68.3	70.3	+2.0	65.7 ± 1.2	68.5 ± 1.5	+2.8
GAT	66.8	60.3	-6.5	68.2 ± 1.1	67.8 ± 3.6	-0.4

Table 2: **Test ROC-AUC (%) performance of different GNN architectures with and without pre-training.** Without pre-training, the less expressive GNNs give slightly better performance than the most expressive GIN because of their smaller model complexity in a low data regime. However, with pre-training, the most expressive GIN is properly regularized and dominates the other architectures. For results split by chemistry datasets, see Table 4 in Appendix H. Pre-training strategy for chemistry data: Context Prediction + Graph-level supervised pre-training; pre-training strategy for biology data: Attribute Masking + Graph-level supervised pre-training.

Strategies for pre-training Graph Neural Network

Conclusion

- Node-level과 graph-level supervised pre-training을 같이 사용했을 때 최대 9.4% 성능 향상
- 라벨이 부족하거나 분포가 다른 환경에서도 강력한 일반화 성능과 빠른 속도

Contribution

- 기존의 single-level 사전학습의 한계를 규명하고, Negative Transfer 문제를 최초로 공식화함
- 지역적 맥락을 읽고 속성 규칙을 배우는 전략을 제안하고 graph-level 학습과 결합하여 성능 극대화

Limitation

- GAT 등 특정 메커니즘을 가진 모델에서는 negative transfer 문제를 피할 수 없었음

