

Node2vec and Struc2vec under Homophily and Structural equivalence

Chae Won Park

**Network Science Lab
Dept. of Artificial Intelligence
The Catholic University of Korea**

E-mail: codnjsld@catholic.ac.kr

Contents




- Introduction
 - Background
 - Purpose
- node2vec
 - motivation
 - Method
 - Experiments
- Struc2vec
 - motivation
 - Method
 - Experiments
- Conclusion
 - Future work - GNN


Background

- **Homophily** : 그래프에서 유사한 특성을 가진 노드들이 연결되는 경향
ex) 네트워크 상에서 비슷한 속성이나 관심사를 가진 노드들이 서로 연결되는 현상
- **Structural Equivalence (Heterophily)** : 그래프에서 노드 간의 관계가 유사한 경우
ex) 두 노드가 비슷한 이웃을 가지고 있거나, 서로 비슷한 다른 노드와 연결되어 있는 경우


Homophily



Heterophily



Background



→ DFS

- 한 노드에서 시작하여 가능한 한 깊이 들어가서 이웃 탐색
- 노드의 근접 이웃들과 연결된 더 멀리 있는 '이웃' 우선 탐색
- Homophily 기반

→ BFS


- 노드와 동일한 거리에 있는 이웃 우선 탐색
- 주변 이웃의 역할을 파악
- Structural equivalence 기반

Limitation of previous study


- 기존 모델들은 homophily 관점에 치우친 경향
- 멀리 떨어져 있어도 역할이 같은 구조적 역할의 특성을 반영하는 데에 한계
ex) DeepWalk

Purpose of study

- Node2vec과 struc2vec 모델을 통해 관점에 따른 임베딩 결과 비교



(a) Input: Karate Graph



(b) Output: Representation

2nd-order random walk


- DeepWalk는 현재 위치만 보고 다음을 결정하지만, node2vec은 어디서 왔는지까지 고려하여 확률을 계산
- DeepWalk에 p, q 파라미터를 추가해 random walk의 편향을 조정 (biased random walk)
- node $t \rightarrow v$ 순서로 이동한 상태에서 다음 node x 를 결정

Return parameter p

- 이전 노드로 즉시 되돌아갈 가능성
- low p : 이미 방문했던 노드로 되돌아감


In-out parameter q

- 내부, 외부 노드 구분
- high $q > 1$: BFS
- low $q < 1$: DFS




$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & \text{if } d_{tx} = 0 \quad \text{t로 즉시 되돌아감} \\ 1 & \text{if } d_{tx} = 1 \quad \text{t와 연결된 다른 이웃 노드로 이동} \\ \frac{1}{q} & \text{if } d_{tx} = 2 \quad \text{t와 상관없는 새로운 노드로 이동} \end{cases}$$

Case study - Les Misérables network



- $p=1, q=0.5$
- Homophily
- Coappearances 기반




- $p=1, q=2$
- structural equivalence

Ex)

- 파란색 노드 : 상위 노드와 하위 노드를 연결하는 다리 역할
- 노란색 노드 : 주로 주변부에 위치하고 제한된 상호작용

Multi-label classification




- x축 : labeled data 비율
- y축 : Micro-F1, Macro-F1
- Table : Micro-F1 scores

Algorithm	Dataset		
	BlogCatalog	PPI	Wikipedia
Spectral Clustering	0.0405	0.0681	0.0395
DeepWalk	0.2110	0.1768	0.1274
LINE	0.0784	0.1447	0.1164
node2vec	0.2581	0.1791	0.1552
node2vec settings (p,q)	0.25, 0.25	4, 1	4, 0.5
Gain of node2vec [%]	22.3	1.3	21.8

- BlogCatalog - p,q 값을 낮게 설정함으로써 homophily 와 structural equivalence를 적절히 조정


Multi-label classification



Algorithm	Dataset		
	BlogCatalog	PPI	Wikipedia
Spectral Clustering	0.0405	0.0681	0.0395
DeepWalk	0.2110	0.1768	0.1274
LINE	0.0784	0.1447	0.1164
node2vec	0.2581	0.1791	0.1552
node2vec settings (p,q)	0.25, 0.25	4, 1	4, 0.5
Gain of node2vec [%]	22.3	1.3	21.8

- PPI – node2vec(p=4, q=1)과 DeepWalk(p=1, q=1) 성능이 비슷
- p를 높게 설정해 중복 방문을 억제하여 근소하게나마 DeepWalk보다 좋은 성능을 냄 (효율성 극대화)
- 그래도 LINE 보다는 훨씬 높다 (23.8%)


Multi-label classification



Algorithm	Dataset		
	BlogCatalog	PPI	Wikipedia
Spectral Clustering	0.0405	0.0681	0.0395
DeepWalk	0.2110	0.1768	0.1274
LINE	0.0784	0.1447	0.1164
node2vec	0.2581	0.1791	0.1552
node2vec settings (p,q)	0.25, 0.25	4, 1	4, 0.5
Gain of node2vec [%]	22.3	1.3	21.8


- Wikipedia – DeepWalk 대비 21.8%, LINE 대비 33.2% 높은 성능
- Wikipedia는 복잡한 구조를 가지고 있어 node2vec 이 찾은 최적의 파라미터를 통해 이러한 구조를 더 깊고 정확하게 탐색할 수 있었음

Multi-label classification



- labeled data가 10%밖에 없는 상황에서 node2vec의 점수는 LINE, Spectral Clustering 90%보다 훨씬 높거나 비슷함
- 데이터가 부족한 실제 환경에서 실용적임을 증명
- node2vec 그래프 기울기를 보면 10~20% 구간에서 성능이 급격하게 증가
- labeled data의 양이 적어도 네트워크의 구조를 빠르게 파악해서 높은 정확도를 낼 수 있음을 증명


Parameter Sensitivity



- homophily와 structural equivalence가 혼합된 특성을 가진 BlogCatalog 데이터셋 이용
- low p – 시작 노드에서 너무 멀어지지 않게 균형을 잡아줌
- low q – 외부로 뻗어 나가는 탐색을 도움
- p 와 q 를 낮게 조절하여 최적의 성능을 냄
- d – 차원이 늘어날수록 성능이 급격히 향상되다가 7~8 부근에서 포화 상태
- r, l – 증가할수록 성능이 좋아짐 (k 가 증가하기 때문)
- k – 커질수록 성능이 전반적으로 향상되지만, 18 부근에서 노이즈 유입 및 관계의 희석으로 성능이 정체되거나 미세하게 감소

motivation

- Node2vec의 한계 – random walk 기반이기 때문에 두 노드가 가깝거나, 연결되어 있어야만 유사도 측정 가능
- Struc2vec을 도입하여 연결성을 무시하고 전역적 영역에서 노드의 역할만 고려함
- Structural equivalence



mechanism

1. Measuring structural similarity

- 차수가 같으면 두 노드는 유사하다
- 두 노드의 이웃들의 차수가 같으면 더 유사하다

$$f_k(u, v) = f_{k-1}(u, v) + g(s(R_k(u)), s(R_k(v))),$$

$$k \geq 0 \text{ and } |R_k(u)|, |R_k(v)| > 0$$

이전 단계까지 쌓인 거리
+
현재 거리에서 발생한 차이

- DTW(Dynamic Time Warping) : d를 합산하여 구함
차수가 1/2인 노드의 차이는 크지만, 101/102인 노드의 차이는 작다고 판단하기 위해 g 산출

$$d(a, b) = \frac{\max(a, b)}{\min(a, b)} - 1$$

- k : 거리 단계
- $R_k()$: 노드에서 k만큼 떨어진 지점에 있는 노드들의 집합
- $s()$: 정렬된 차수 수열
- f : 구조적 거리

mechanism

2. Constructing the context graph

- 계층적인 구조 정보를 담은 새로운 가중치 그래프를 만듦
- 거리와 가중치가 반비례함

$$w_k(u, v) = e^{-f_k(u, v)}, \quad k = 0, \dots, k^*$$

가중치 그래프

$$w(u_k, u_{k+1}) = \log(\Gamma_k(u) + e), \quad k = 0, \dots, k^* - 1$$

$$w(u_k, u_{k-1}) = 1, \quad k = 1, \dots, k^*$$

- 상향 이동 : 현재 층에서 나와 닮은 노드가 많아서 구분이 잘 안 될 때 더 까다로운 기준 (더 먼 이웃 고려)
- 하향 이동 : 기준 완화 (포괄적 구조)

$$\Gamma_k(u) = \sum_{v \in V} \mathbb{1}(w_k(u, v) > \overline{w_k})$$

- 조건을 만족하면 1을 반환하는 함수
- 자신과의 유사도가 평균보다 높은 노드의 개수의 합

$$\overline{w_k} = \sum_{(u, v) \in \binom{V}{2}} w_k(u, v) / \binom{n}{2}$$

평균

mechanism

3. Generating context for nodes

- Biased 랜덤 워크를 통한 문맥 생성

$$p_k(u, v) = \frac{e^{-f_k(u, v)}}{Z_k(u)}$$

현재 층에서 다른 노드로 이동할 확률

$$Z_k(u) = \sum_{\substack{v \in V \\ v \neq u}} e^{-f_k(u, v)}$$

정규화 계수

$$p_k(u_k, u_{k+1}) = \frac{w(u_k, u_{k+1})}{w(u_k, u_{k+1}) + w(u_k, u_{k-1})}$$
$$p_k(u_k, u_{k-1}) = 1 - p_k(u_k, u_{k+1})$$

- 확률이 1-q면 층을 옮김
- P가 층 내 / 위아래 층 이동 결정

mechanism


4. Learning a language model

- Skip-gram 모델 사용 (중심->주변)
- W가 문맥으로 인정할 범위를 결정

$$P(v_j|v_i) = \prod_{k=1}^h C(n(v_j, k), v_i)$$


- 계층적 소프트맥스
- C : 이진 분류기
- $n(v_j, k)$: 목표 노드 v_j 에 가기 위해 거쳐야 하는 경로 중 k 번째에 위치한 트리 내부 노드
- v_i : 중심 노드의 임베딩 벡터

Barbell graph





- RolX vs struc2vec
- Homophily vs structural equivalence
- OPT1 : 비슷한 차수를 가진 노드 그룹화
- OPT2 : 차수가 비슷한 노드들끼리만 유사도 계산
- OPT3 : 레이어 수 제한

Karate network





- 데이터를 복제하고, 1번과 37번 사이에 edge 하나만 추가
- “서로 다른 덩어리에 있어 물리적 거리가 매우 먼 미러 노드들을 struc2vec이 묶을 수 있는가?”



Karate network


(a)



(c) *struc2vec*

Future work - GNN

- Struc2vec의 한계 - 이 네트워크 구조에 집착하는 경향이 있기 때문에, 실제 데이터에서 노드 자체에 중요한 정보가 담겨있는 것을 임베딩 과정에서 버림
- 이웃의 데이터와 구조적 위치를 동시에 계산하는 함수를 학습하는 GNN으로 해결



How to learn mapping function f ?