

Improving Subgraph Recognition with Variational Graph Information Bottleneck

CHAE WON PARK

Network Science Lab
Dept. of Artificial Intelligence
The Catholic University of Korea

E-mail: codnjsld@catholic.ac.kr



가톨릭대학교
THE CATHOLIC UNIVERSITY OF KOREA

Contents



- Introduction
 - Background
 - Related work
- Methods
 - Noise Injection
 - VGIB
- Experiments
 - Graph Interpretation
 - Explainability of GCN
 - Graph Classification

Background

- GNN 모델은 다양한 분야에서 뛰어난 예측력을 가짐
- 하지만 왜 그런 예측을 했는지 설명하기 어렵다는 문제
- 부분 그래프 인식을 통해 GNN의 예측에 중요한 영향을 미친 핵심적인 부분 그래프를 찾아내서 GNN의 설명 방법을 높임
- **부분 그래프 인식(Subgraph Recognition)**의 목표 : 그래프 전체의 어떤 속성을 가장 잘 예측하면서도 동시에 압축된 형태의 그래프를 찾는 것
 - Predictive : 그래프가 원본 그래프의 특정 속성을 예측하는 데 매우 유용하다.
 - Compressed : 원본 그래프에 비해 훨씬 작거나, 원본 그래프의 불필요한 정보(노이즈, 중복 정보)를 상당 부분 제거했다.

Background

- **상호 정보(Mutual Information, MI)** : 두 확률 변수 X, Y 가 있을 때, X 를 알게 됨으로써 Y 에 대해 얼마나 더 많이 알게 되는지를 정량화하는 것

$$I(X, Y) = \int_X \int_Y p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy$$

- **정보 병목(information Bottleneck, IB)** : 입력 변수 X 로부터 대상 변수 Y 를 예측하는 데 필요한 가장 압축된 표현인 Z 를 찾으려고 함

$$\min_Z I(Z; Y) - \beta I(Z; X)$$

- **Graph Information Bottleneck(GIB)** : 정보 병목 IB를 그래프 데이터에 적용해서 그래프 G로부터 그래프의 레이블 Y를 예측하는 데 필요한 가장 압축된 부분 그래프 Gsub를 찾으려고 한다.
 - 정보성(predictiveness) : Gsub가 Y에 대해 유용한 정보를 많이 포함해야 함
 - 압축성(compressiveness) : Gsub는 G에 비해 정보량이 적어야 함

$$\min_{G_{sub}} -I(G_{sub}, Y) + \beta I(G_{sub}, G)$$

최대화
최소화

Related work

• Limitation of GIB

- 상호 정보 추정기가 부정확하거나 불안정함
- 학습이 불안정하면 원본 그래프의 정보를 제대로 압축하지 못하거나, 레이블 예측에 도움되지 않는 부분 그래프를 얻게 됨
- 상호 정보 추정 과정 자체가 계산적으로 복잡하고 시간이 많이 소요됨
- 그래프가 이산적이고 불규칙한 구조를 가지기 때문에 부분 그래프의 분포를 정확하게 모델링하는 것이 어려움




Figure 1. Training dynamics of VGIB and GIB. $\mathcal{L}_{cls}$ and $\mathcal{L}_{MI}$ refer to the prediction and compression term of two methods. (a). VGIB converges fast and stable. (b). GIB suffers from an unstable training process and inaccurate estimation of mutual information in the red circle (mutual information is non-negative).

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함

$$\min_{G_N} -I(G_N, Y) + \beta I(G_N, G)$$

목적 함수

$$I(G_{sub}, G_n) \leq I(G_N, G_n) \leq I(G_N, G) - I(G_N, Y)$$

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- I. **그래프 교란 Graph Perturbation** : 원본 그래프 G의 정보를 조절하여, 레이블 속성에는 중요하고 다른 정보에는 덜 중요한 변형된 그래프 G_n 을 생성하는 단계

1. 노이즈 주입 메커니즘

$$\begin{aligned}
 H &= \text{GNN}(A, X; W^1, \dots, W^l) \\
 &= \underbrace{\sigma(D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \dots \sigma(D^{-\frac{1}{2}} A D^{-\frac{1}{2}} X W^1)) \dots W^l}_{l\text{-layer}}
 \end{aligned}$$

- L개의 레이어를 가진 GNN이 그래프의 인접 행렬 A와 초기 노드 특징 X를 사용하여 노드 표현 H를 학습함

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- I. **그래프 교란 Graph Perturbation** : 원본 그래프 G의 정보를 조절하여, 레이블 속성에는 중요하고 다른 정보에는 덜 중요한 변형된 그래프 G_n 을 생성하는 단계

1. 노이즈 주입 메커니즘

$$p_i = \text{Sigmoid}(\text{MLP}(h_i))$$

- 각 노드 i에 대해 해당 노드 표현 h_i 로부터 얼마나 많은 정보가 유지될지를 결정하는 확률 p_i 를 학습
- 원본 노드 i의 표현 h_i 가 변형된 노드 z_i 로 전달될 확률

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- I. **그래프 교란 Graph Perturbation** : 원본 그래프 G의 정보를 조절하여, 레이블 속성에는 중요하고 다른 정보에는 덜 중요한 변형된 그래프 Gn을 생성하는 단계

1. 노이즈 주입 메커니즘

$$z_i = \lambda_i h_i + (1 - \lambda_i) \epsilon$$

- 노이즈 주입을 통해 원래 노드 표현 h_i 의 정보량을 조절함

$$\epsilon_G \sim \mathcal{N}(\mu_h, \sigma_h^2)$$

- 노이즈는 각 입력 그래프의 노드 표현들의 통계적 특성(평균과 분산)을 반영한 가우시안 분포에서 샘플링되어 의미론적 정의를 보존한다.

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- I. **그래프 교란 Graph Perturbation** : 원본 그래프 G의 정보를 조절하여, 레이블 속성에는 중요하고 다른 정보에는 덜 중요한 변형된 그래프 Gn을 생성하는 단계

1. 노이즈 주입 메커니즘

$$z_i = \lambda_i h_i + (1 - \lambda_i) \epsilon$$

- 노이즈 주입을 통해 원래 노드 표현 h_i 의 정보량을 조절함

$$\hat{\lambda}_i = \text{Sigmoid}\left(\frac{1}{t} \log \frac{p_i}{1 - p_i} + \log \frac{u}{1 - u}\right)$$

- 이산적인 확률 변수 λ_i 를 근사하여, 역전파를 통해 p_i 를 학습할 수 있도록 하는 Gumbel-Softmax 기법을 적용

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- 1. **그래프 교란 Graph Perturbation** : 원본 그래프 G 의 정보를 조절하여, 레이블 속성에는 중요하고 다른 정보에는 덜 중요한 변형된 그래프 G_N 을 생성하는 단계

2. **VGIB 목적 함수 최적화** : 생성된 교란된 그래프 G_N 을 사용하여 핵심 목적 함수를 최소화함

$$\mathcal{L} = \mathcal{L}_{\text{cls}}(G_N, Y) + \beta \mathcal{L}_{\text{MI}}(Z_N, G)$$


$\mathcal{L}_{\text{cls}}(G_N, Y)$
 G_N 이 Y 를 얼마나
 잘 예측하는지 측정

$\mathcal{L}_{\text{MI}}(Z_N, G)$
 G_N 이 G 로부터 얼마나
 압축되었는지 측정

- VGIB 프레임워크의 전체 손실 함수
- 3. 학습의 결과 : 이 단계의 학습을 통해 각 노드에 대한 최적의 p_i 값이 결정됨
 - 중요한 노드 : p_i 값 높아서 정보 보존
 - 중요하지 않은 노드 : p_i 값 낮아서 노이즈로 대체

VGIB

- **Variational Graph Information Bottleneck(VGIB)** : 상호 정보 MI를 직접 추정하는 대신, 압축의 개념을 원본 그래프의 정보에 의도적으로 노이즈를 주입하여 중요한 부분만 남기는 방식으로 대체함
- II. **부분 그래프 선택 Subgraph Selection** : 그래프 교란 단계가 완료된 후, 학습된 노이즈 주입 확률 p_i 값을 기반으로 실제 핵심 부분 그래프 G_{sub} 를 추출하는 단계
 1. **확률 기반 필터링** : 학습된 p_i 값을 사용하여 특정 임계값 이상의 노드들만을 선택함
 2. **부분 그래프 구성** : 선택된 노드들과 이들 노드들 사이에 원본 그래프에 존재했던 연결만을 포함하여 최종 부분 그래프 G_{sub} 를 구성함



Graph Interpretation

- Fidelity+ $\uparrow$: subgraph가 GNN의 원래 예측과 얼마나 일치하는지를 나타냄
- Fidelity- $\downarrow$: 설명된 subgraph를 제거했을 때 GNN의 예측이 얼마나 달라지는지(떨어지는지)를 나타냄

Table 3. Performance of different methods on explaining the predictions of GCN in terms of fidelity scores. We set the sparsity score of the explanatory subgraphs as 0.5 for a fair comparison.

Metric	Fidelity+ $\uparrow$				Fidelity- $\downarrow$			
Property	RLM-Clint	HLM-Clint	QED	DRD2	RLM-Clint	HLM-Clint	QED	DRD2
GNNExplainer	0.694	0.778	0.602	0.74	0.478	0.616	0.498	0.433
PGExplainer	0.632	0.692	0.598	0.686	0.502	0.62	0.56	0.54
GraphMask	0.632	0.706	0.602	0.673	0.516	0.592	0.574	0.4866
IGExplainer	0.684	0.758	0.592	0.693	0.602	0.686	0.584	0.58
GraphGrad-CAM	0.67	0.782	0.586	0.659	0.56	0.668	0.564	0.566
GIB	0.654	0.781	0.601	0.724	0.483	0.643	0.525	0.428
VGIB	0.765	0.792	0.627	0.756	0.463	0.579	0.487	0.424

Explainability of GCN

- GNN 모델과 GIB/VGIB 프레임워크와 결합했을 때 여러 데이터셋에서의 성능 비교

Table 4. Classification accuracy of graphs with **sum pooling** and **mean pooling** as the readout function. We report the mean and standard deviation of the testing accuracy in 10-fold cross-validation for each method. The bold results are the overall best performances and the underlining results are the best performances of certain backbones.

	Method	MUTAG	PROTEINS	IMDB-B	DD	COLLAB	REDDIT-B
Sum pooling	GCN	0.76±0.09	0.72±0.05	0.71±0.04	0.74±0.03	0.78±0.03	0.75±0.05
	GIB+GCN	0.77±0.07	<u>0.74±0.04</u>	0.72±0.04	0.75±0.05	0.78±0.02	0.77±0.04
	VGIB+GCN	<u>0.79±0.09</u>	<u>0.74±0.04</u>	<u>0.74±0.04</u>	<u>0.77±0.09</u>	0.80±0.02	<u>0.82±0.02</u>
	GraphSAGE	0.74±0.08	0.73±0.05	0.71±0.05	0.75±0.03	0.78±0.02	0.78±0.10
	GIB+GraphSAGE	0.75±0.07	0.73±0.04	0.72±0.05	0.76±0.04	0.79±0.02	<u>0.80±0.03</u>
	VGIB+GraphSAGE	<u>0.77±0.07</u>	<u>0.74±0.04</u>	<u>0.73±0.03</u>	0.78±0.05	0.80±0.03	<u>0.80±0.09</u>
	GIN	0.83±0.07	0.74±0.05	0.71±0.05	0.71±0.03	0.78±0.02	0.81±0.10
	GIB+GIN	0.84±0.06	0.74±0.05	0.74±0.07	0.74±0.04	0.78±0.03	0.84±0.03
	VGIB+GIN	0.86±0.08	0.75±0.04	0.74±0.05	<u>0.75±0.04</u>	<u>0.79±0.03</u>	0.86±0.03
	GAT	0.75±0.08	0.72±0.04	0.72±0.03	0.75±0.04	0.76±0.04	0.71±0.08
	GIB+GAT	0.75±0.09	0.73±0.04	0.72±0.05	0.76±0.04	0.77±0.03	0.73±0.04
	VGIB+GAT	<u>0.76±0.07</u>	<u>0.73±0.04</u>	<u>0.73±0.07</u>	<u>0.77±0.04</u>	<u>0.79±0.03</u>	<u>0.76±0.05</u>
	GCN	0.72±0.11	0.71±0.04	0.71±0.04	0.72±0.05	0.77±0.02	0.75±0.06
	GIB+GCN	0.74±0.08	0.72±0.05	0.72±0.03	0.74±0.05	0.78±0.02	0.76±0.04
	VGIB+GCN	<u>0.76±0.10</u>	<u>0.73±0.04</u>	<u>0.73±0.04</u>	<u>0.75±0.10</u>	0.79±0.02	<u>0.78±0.02</u>
Mean pooling	GraphSAGE	0.73±0.07	0.72±0.04	0.70±0.04	0.73±0.04	0.77±0.02	0.78±0.03
	GIB+GraphSAGE	0.74±0.07	0.72±0.04	0.72±0.05	0.74±0.04	<u>0.78±0.03</u>	0.79±0.03
	VGIB+GraphSAGE	0.75±0.08	<u>0.73±0.04</u>	<u>0.73±0.03</u>	0.76±0.05	<u>0.78±0.03</u>	<u>0.80±0.03</u>
	GIN	0.82±0.07	0.71±0.06	0.72±0.05	0.73±0.03	0.78±0.03	0.82±0.02
	GIB+GIN	0.83±0.06	0.71±0.05	0.73±0.07	0.74±0.04	0.78±0.03	0.84±0.04
	VGIB+GIN	0.84±0.09	<u>0.72±0.05</u>	0.74±0.05	<u>0.75±0.04</u>	<u>0.79±0.03</u>	0.85±0.03
	GAT	0.74±0.08	0.71±0.04	0.71±0.04	0.70±0.06	0.76±0.03	0.77±0.04
	GIB+GAT	0.75±0.10	0.73±0.04	0.72±0.05	0.72±0.04	0.77±0.03	<u>0.79±0.04</u>
	VGIB+GAT	<u>0.76±0.07</u>	0.74±0.03	<u>0.73±0.07</u>	<u>0.73±0.05</u>	<u>0.78±0.03</u>	<u>0.79±0.05</u>

Graph Classification

- GNN 예측에 대한 다양한 설명 방법들의 성능을 평가한 결과




Figure 4. Performance of different methods on explaining the predictions of GCN in terms of fidelity scores ($Fidelity+$ $\uparrow$ and $Fidelity-$ $\downarrow$). VGIB generates the most faithful explanations to the predictions of GCN by identifying the most important nodes under different sparsity scores.

